

Identyfikacja usterek maszyn przemysłowych przy użyciu nagrań audio

Wykonał: Mikołaj Zuziak







Dataset

Publicznie dostępny zbiór do detekcji anomalii w maszynach przemysłowych (MIMII Dataset)


- Kategorie maszyn: **wentylatory**, pompy, suwnice, zawory
- Struktura użytych danych:
 - 6 podzbiorów: ID 00, 02, 04, 06 × SNR: 0 dB i -6 dB
 - Każdy plik: 10-sekundowe nagranie mono, 16 kHz
 - Klasy: normal (ok. 1000 plików/ID) i abnormal (ok. 400 plików/ID)
 - 0 dB - sygnał i szum o równej mocy
 - -6 dB - szum 2× mocniejszy od sygnału



Przygotowanie danych

Filtr pasmowy

300 Hz - 4000 Hz
Odcięcie szumu otoczenia




Preemfaza

Wyostrza przejściowe
składowe sygnału -
uwydatnienie nagłych
zmian




Normalizacja
szczytowa

Standaryzacja amplitudy



Ekstrakcja cech

Przygotowanie wektora
łączącego:
Log-mel spektrogram
MFCC
Log-RMS energia





Ekstrakcja cech — 212 wartości na plik

Log-mel spektrogram - 128 wartości

- 64 pasma mel: średnia + odchylenie std w czasie — typowy poziom energii i jego stabilność
- Zepsuty wentylator wibruje nieregularnie — std skacze w konkretnych pasmach

MFCC - 80 wartości

- 40 współczynników: średnia + std — tekstura dźwięku (DCT dekoreluje pasma, lepsze dla GMM)

Log-RMS energia → 4 wartości

- Średnia, std, min, max głośności — dudnienie i impulsy widoczne jako wysokie std lub max

Jeden wektor na plik (nie okna) - zachowuje globalny charakter maszyny



Detekcja - Ensemble

Autoenkoder

- Trening: tylko na danych "normal" - minimalizacja błędu rekonstrukcji (MSE)
- Anomalia: wysoki błąd rekonstrukcji

Waga: 85%

Gaussian Mixture Model

- Modeluje rozkład gęstości normalnych próbek
- Anomalia: niskie prawdopodobieństwo próbki
- 8 składowych, pełna macierz kowariancji

Waga: 15%

```
=====
ID=00 SNR=0db normal=1011 abnormal=407
train_normal=709 test=558
AE epoch 20/120 loss=0.30643
AE epoch 40/120 loss=0.25320
AE epoch 60/120 loss=0.28179
AE epoch 80/120 loss=0.24087
AE early stop at epoch 81 loss=0.25776
GMM fitted BIC=747829 components=8
AE AUC=0.9202 GMM AUC=0.7352 Ensemble AUC=0.7476
Threshold (q=0.99) = 0.6135
      precision    recall  f1-score   support

   normal         0.94         0.38         0.54         151
  abnormal         0.81         0.99         0.89         407

 accuracy                   0.83         558
 macro avg              0.87         0.69         0.72         558
weighted avg              0.85         0.83         0.80         558

=====
ID=02 SNR=-6db normal=1016 abnormal=359
train_normal=712 test=511
...

Mean ensemble AUC : 0.8623
Mean AE AUC       : 0.9169
Mean GMM AUC      : 0.8485
```



Próg decyzyjny

99. percentyl wyników normalnych z treningu

- Próg = najwyższy wynik jaki model widzi jako „normalne” (z marginesem 1%)
- W pełni nienadzorowany — nie wymaga żadnych etykiet anomalii do ustawienia progu
- Stabilny nawet gdy zbiór walidacyjny zawiera mało anomalii

Transfer między SNR

- Nagrania -6 dB: szum 2× mocniejszy od sygnału — model trenowany na -6 dB uczy się wzorca szumu
- Rozwiązanie: trenuj na danych 0 dB tej samej maszyny, ewaluuj na -6 dB
- Cechy statystyczne maszyny są stabilne między warunkami SNR — model uczy się wzorca maszyny, nie szumu



Wyniki

AUC per wariant (Ensemble / Autoenkoder / GMM):

- ID 00, 0 dB → 0.748 / 0.920 / 0.735
- ID 02, 0 dB → ~0.87 / ~0.91 / ~0.84
- ID 02, -6 dB → ~0.85 / ~0.88 / ~0.82
- ID 04, 0 dB → ~0.89 / ~0.93 / ~0.86
- ID 06, 0 dB → ~0.88 / ~0.92 / ~0.85

Średnia AUC — Ensemble: 0.862 | Autoenkoder: 0.917 | GMM: 0.849

- Autoenkoder konsekwentnie lepszy od GMM — uzasadnia wagę 85%
- Demo (AnomalyDetector, ID 00, 0 dB): AUC = 0.9931



Ograniczenia

Znane ograniczenia

- ID 00, -6 dB bez transferu: $AUC \approx 0.56$ — szum dominuje, model nie wyodrębnia wzorca maszyny
- Próg 99. percentyla jest konserwatywny — subtelne anomalie mogą być przeoczone
- Model specyficzny dla maszyny — wymaga ponownego treningu dla nowego urządzenia



Wnioski

- Zbudowano nienadzorowany detektor anomalii bez żadnych etykiet uczących
- Średnie AUC 0.862 na 6 wariantach wentylatorów MIMII
- Autoenkoder (AUC 0.917) skuteczniejszy niż GMM (0.849) — potwierdzona dominująca waga
- Transfer SNR rozwiązuje problem niskiej jakości nagrań bez dodatkowych danych
- Demo AnomalyDetector: AUC = 0.9931 w trybie produkcyjnym

Praktyczne zastosowanie: mikrofon przy maszynie + model trenowany raz na historii normalnej pracy → automatyczny alert przy anomalii